

BÀI TẬP LỚN SỐ 1

Classification

Phân loại trên dữ liệu Ảnh, Văn bản và Đa phương thức

Instructor:

TS Lê Thành Sách

Trần Lê Phú

2470307

Huỳnh Văn Tâm Thiện

2470094

DANH MỤC

01

IMAGE
CLASSIFICATION

02

TEXT
CLASSIFICATION

03

MULTIMODAL
CLASSIFICATION

01 IMAGE CLASSIFICATION

AGENDA

01

DATASET & EDA

02

AUGMENTATION &
DATALOADER

03

HUẤN LUYỆN & SO SÁNH

04

MỞ RỘNG & KẾT LUẬN

Tổng quan tập dữ liệu

Nguồn: Oxford-IIIT Pet Dataset

Số lớp: 37 giống thú cưng (25 chó + 12 mèo)

Tổng số ảnh: ~7,349 gốc $\rightarrow$ 2,543 ảnh hợp lệ (sau lọc hỏng)

Đặc điểm: Ảnh đa dạng góc chụp, ánh sáng, nền — độ khó trung bình-cao

Chia dữ liệu: Stratified split 80/20 $\rightarrow$ Train: 2,034 / Test: 509

Input size: 224×224 (chuẩn ResNet50 & ViT-B/16)

Phân bố: Tương đối cân bằng, trung bình ~199 ảnh/lớp.

Phân tích dữ liệu (EDA)

Phân bố lớp

37 lớp phân bố tương đối đều. Tỷ lệ max/min thấp → dataset khá cân bằng.

Kích thước ảnh gốc

Rất đa dạng (vài trăm → vài nghìn pixel). Cần resize về 224×224.

Ảnh hỏng

Phát hiện & loại 4,806 ảnh hỏng. Còn 2,543 ảnh hợp lệ.

Đặc trưng ảnh

Nền đa dạng (trong nhà, ngoài trời). Một số lớp rất giống nhau (Bengal ↔ Egyptian Mau, Chihuahua ↔ Miniature Pinscher).

Augmentation & DataLoader

Train Transform (có augmentation):

- `Resize(256) → RandomResizedCrop(224) → RandomHorizontalFlip`
- `RandomRotation( $\pm 15^\circ$ ) → ColorJitter → RandomGrayscale(5%)`
- `ToTensor → Normalize(ImageNet mean/std)`

Test Transform:

- `Resize(256) → CenterCrop(224) → ToTensor → Normalize`

Tác động Augmentation (ResNet50):

- Có Augmentation: Accuracy = 0.8939
 - Không Augmentation: Accuracy = 0.3536 (giảm -54%!)
- Augmentation cực kỳ quan trọng cho dataset nhỏ.

HUẤN LUYỆN & SO SÁNH

Kiến trúc mô hình

ResNet50 (CNN)

Pretrained ImageNet, 23.6M params

- Phase 1: Freeze backbone → train head (3 ep)
- Phase 2: Unfreeze all, lr thấp (9 ep)

Freeze: Acc = 0.8664

Fine-tune: Acc = 0.8939

ViT-B/16 (Vision Transformer)

Pretrained ImageNet, 85.8M params

- Phase 1: Freeze backbone → train head (6 ep)
- Phase 2: Unfreeze all, lr thấp (11 ep)

Freeze: Acc = 0.9352

Fine-tune: Acc = 0.9391


ViT-B/16 vượt trội ở cả 2 phase. Chỉ freeze backbone đã đạt 93.5%.

Bảng tổng hợp kết quả

Mô hình	Accuracy	F1 (macro)	F1 (weighted)
ResNet50 (Freeze)	0.8664	0.8664	0.8664
ResNet50 (Fine-tune)	0.8939	0.8926	0.8942
ViT-B/16 (Freeze)	0.9352	0.9352	0.9352
ViT-B/16 (Fine-tune)	0.9391	0.9374	0.9392
Avg / Weighted Ensemble	0.9411	0.9393	0.9412

Ensemble đạt cao nhất (94.11%). ViT-B/16 đơn lẻ đã rất mạnh (93.91%).

So sánh Accuracy



MỞ RỘNG

Grad-CAM & Phân tích lỗi

Grad-CAM Visualization

- ResNet50: Tập trung vùng cục bộ (mặt, tai, lông)
- ViT-B/16: Chú ý phân tán, bao quát toàn bộ đối tượng
→ *CNN convolution (cục bộ) vs ViT self-attention (toàn cục)*

Phân tích lỗi

- Cả 2 đúng: 444 mẫu (87.2%) | Cả 2 sai: 20 mẫu (3.9%)
- Chỉ ResNet50 sai: 34 | Chỉ ViT sai: 11

Top cặp dễ nhầm (ResNet50):

- Bengal → Egyptian Mau (5), American Bulldog → Boxer (3), Chihuahua → Miniature Pinscher (3)

Robustness & Calibration

Robustness (Noise / Blur / Brightness)

Nhiều	Mức	ResNet50	ViT-B/16
Clean	0	0.894	0.939
Gauss noise	1	0.811	0.916
Gauss noise	3	0.354	0.872
Blur	2	0.287	0.821
Brightness	3	0.845	0.924

Suy giảm TB: ResNet -23.4% vs ViT -5.4%. ViT robust hơn rõ rệt.

Calibration (ECE)

Mô hình	ECE ↓
ViT-B/16	0.0354
Avg Ensemble	0.1963
ResNet50	0.3600

ViT calibrated tốt nhất ($ECE=0.035$). ResNet kém ($ECE=0.360$).

Efficiency & Ensemble

So sánh hiệu quả

	ResNet50	ViT-B/16
Params	23.6M	85.8M
Size	90 MB	327 MB
Latency	2.83 ms	11.10 ms
Accuracy	0.894	0.939

ResNet nhỏ 3.6x, nhanh 3.9x nhưng acc thấp hơn 4.5%.

Ensemble Results

Average & Weighted Ensemble:

Accuracy = 0.9411

F1 (macro) = 0.9393

Trọng số: ResNet=0.488, ViT=0.512

Cải thiện +0.2% so với ViT đơn lẻ. Sự đa dạng kiến trúc CNN ≠ ViT giúp ensemble hiệu quả.

Kết luận

- ViT-B/16 vượt trội: Acc 93.91% vs ResNet50 89.39% (+4.5%). Freeze backbone đã đạt 93.52%.
- Ensemble (CNN+ViT) đạt cao nhất (94.11%) nhờ kết hợp đặc trưng cục bộ + toàn cục.
- Augmentation cực kỳ quan trọng: Không augment → ResNet chỉ 35.36% (−54%).
- ViT robust hơn (suy giảm −5.4% vs −23.4%) và calibrated tốt hơn (ECE 0.035 vs 0.360).
- Grad-CAM: CNN tập trung cục bộ, ViT bao quát toàn bộ — giải thích ViT tổng quát hóa tốt hơn.
- Error analysis: Lớp dễ nhầm là giống thú cưng ngoại hình gần nhau (Bengal ↔ Egyptian Mau).

02

TEXT

CLASSIFICATION

AGENDA

01

DATASET & EDA

02

HUẤN LUYỆN MÔ HÌNH

03


KẾT QUẢ THỰC NGHIỆM

04

MỞ RỘNG & KẾT LUẬN

Tổng quan tập dữ liệu

- **Tổng số mẫu:** 31.381 văn bản.
- **Loại bài toán:** Phân loại văn bản đa lớp (Multi-class Text Classification).
- **Số lượng nhãn:** 11 lớp (chủ đề) riêng biệt.
- **Danh sách các chủ đề:** *Animals, Health, Love, Religion, Science, Self, Music, v.v.*



Phân tích dữ liệu (EDA)

Phân phối lớp: 11 lớp với tỷ lệ imbalance vừa phải. Không có lớp quá nhỏ, thuận lợi cho huấn luyện.

Độ dài văn bản: Biến thiên lớn (10–1000+ ký tự). Median ~200 ký tự.





Chất lượng dữ liệu: Chỉ 39 bản sao, 0 mẫu rỗng sau làm sạch. Dữ liệu đủ sạch để huấn luyện trực tiếp.

Token-level Analysis: Sử dụng BERT WordPiece tokenizer (vocab = 30,522) cho cả phân tích EDA lẫn huấn luyện.

Data Splitting: Áp dụng chiến lược **Stratified Sampling** để đảm bảo tỉ lệ các lớp đồng nhất giữa các tập dữ liệu:

- **Tập Huấn luyện (Train):** 25.104 mẫu (80%).
- **Tập Kiểm thử (Validation):** 3.138 mẫu (10%).
- **Tập Đánh giá (Test):** 3.139 mẫu (10%).

Phân tích dữ liệu (EDA)




HUẤN LUYỆN MÔ HÌNH

Mô hình Baseline (TF-IDF + Linear SVM)

- **Mục tiêu:** Thiết lập một thang đo tiêu chuẩn (benchmark) để đánh giá hiệu quả của các mô hình Deep Learning và Transformer phức tạp hơn.
- **Lý do lựa chọn TF-IDF + SVM:**
 - Hiệu quả cao với các tập dữ liệu văn bản có quy mô vừa và nhỏ.
 - Tốc độ huấn luyện và suy luận cực nhanh, không yêu cầu tài nguyên phần cứng lớn (GPU).
 - Khả năng giải thích (interpretability) tốt hơn so với các mô hình dạng "black-box".
- **Vai trò:** Xác định mức độ chính xác mà một thuật toán học máy truyền thống có thể đạt được dựa trên đặc trưng tần suất từ.

Mô hình Baseline (TF-IDF + Linear SVM)

TF-IDF + Linear SVM (test) (normalized)



```
baseline val: {'accuracy': 0.6604977664326739, 'macro_f1': 0.6678509698713856, 'micro_f1': 0.6604977664326739}
baseline test: {'accuracy': 0.6755980861244019, 'macro_f1': 0.6825526576924074, 'micro_f1': 0.6755980861244019}
```

	precision	recall	f1-score	support
Animals	0.73	0.70	0.71	262
Compliment	0.77	0.73	0.75	305
Education	0.71	0.65	0.68	253
Health	0.63	0.68	0.65	259
Heavy Emotion	0.55	0.66	0.60	367
Joke	0.78	0.68	0.73	247
Love	0.68	0.66	0.67	323
Politics	0.86	0.80	0.83	220
Religion	0.68	0.66	0.67	346
Science	0.55	0.63	0.59	243
Self	0.63	0.62	0.63	310
accuracy			0.68	3135
macro avg	0.69	0.68	0.68	3135
weighted avg	0.68	0.68	0.68	3135


Mô hình Baseline (TF-IDF + Linear SVM)

- **Hiệu năng:** Accuracy đạt ~80-85%; tốc độ xử lý cực nhanh, tốn ít tài nguyên.
- **Ưu điểm:** Phân loại rất tốt các chủ đề có từ khóa đặc trưng mạnh (ví dụ: *Religion, Animals*).
- **Hạn chế:** Bỏ qua ngữ cảnh và thứ tự từ. Dễ nhầm lẫn giữa các nhãn có từ vựng tương đồng (ví dụ: *Health* và *Science*).

Nhóm mô hình CNN (BiLSTM / BiGRU)

- **Kiến trúc cốt lõi:**
 - **Embedding Layer:** Sử dụng Word Embeddings để chuyển hóa từ vựng thành các vector đặc trưng dày đặc (dense vectors).
 - **Cơ chế Bidirectional (Bi):** Cho phép mô hình học ngữ cảnh từ cả hai phía (trái sang phải và ngược lại), giúp nắm bắt trọn vẹn ý nghĩa của câu thay vì chỉ nhìn theo một chiều.
 - **Shared Tokenizer:** Sử dụng cùng bộ Tokenizer với BERT để đảm bảo tính đồng nhất khi so sánh kết quả.
- **Chi tiết mô hình:**
 - **BiLSTM:** Sử dụng các "cổng" (gates) để duy trì thông tin dài hạn, giảm thiểu vấn đề biến mất đạo hàm (vanishing gradient).
 - **BiGRU:** Phiên bản rút gọn của LSTM, tối ưu về tốc độ huấn luyện nhưng vẫn giữ được hiệu suất tương đương trên tập dữ liệu này.

Nhóm mô hình CNN (BiLSTM / BiGRU)



Nhóm mô hình Transformer

BERT-base (Full Fine-tune)

bert-base-uncased, 110M params. lr = 2e-5, warmup 6%, AdamW.

Test: accuracy = 0.7764, macro F1 = 0.7829 (cao nhất)

DistilBERT (Full Fine-tune)

distilbert-base-uncased, 66M params. Cùng cấu hình huấn luyện.

Test: accuracy = 0.7611, macro F1 = 0.7663

So sánh chiến lược Fine-tune (DistilBERT):

- Freeze backbone: macro F1 = 0.6769, train ~5.4 phút
- Layerwise LR: macro F1 = 0.7716, train ~11.9 phút
- Full fine-tune: macro F1 = 0.7663, train ~10 phút

Layerwise LR đạt chất lượng gần BERT-base với chi phí thấp hơn.


KẾT QUẢ THỰC NGHIỆM

Bảng tổng hợp kết quả

Mô hình	Nhóm	Accuracy	Macro F1
TF-IDF + SVM	Baseline	0.6756	0.6826
BiLSTM	RNN	0.6475	0.6528
BiGRU	RNN	0.6494	0.6540
DistilBERT (freeze)	Transformer	—	0.6769
DistilBERT	Transformer	0.7611	0.7663
DistilBERT (layerwise)	Transformer	—	0.7716
BERT-base	Transformer	0.7764	0.7829
Ensemble (avg prob)	Kết hợp	0.7718	0.7760

BERT-base đạt kết quả tốt nhất với macro F1 = 0.7829, vượt trội so với RNN ~13 điểm phần trăm.

So sánh Macro F1 giữa các mô hình



MỞ RỘNG

Phân tích lỗi & Calibration

Error Analysis

Cặp lớp hay nhầm lẫn nhất:

- Love $\leftrightarrow$ Heavy Emotion
- Science $\leftrightarrow$ Health
- Self $\leftrightarrow$ Heavy Emotion

Nguyên nhân: các lớp có ngữ nghĩa gần gũi, ranh giới mờ giữa cảm xúc và chủ đề liên quan.

Calibration (ECE)

Mô hình	ECE ↓
TF-IDF + SVM	0.0334
BERT-base	0.0425
DistilBERT	0.0515
BiGRU	0.1571
BiLSTM	0.1877

TF-IDF+SVM có ECE tốt nhất; RNN kém calibrated nhất.

Robustness & Interpretability

Robustness Test

- Nhiều áp dụng: Random char delete & char swap
- BERT-base F1: 0.7842 $\rightarrow$ 0.7541 (delete) $\rightarrow$ 0.7676 (swap)
- Mọi mô hình đều giảm điểm. Transformer bền hơn RNN.

Interpretability

- Phương pháp: Attention visualization + Gradient-based attribution
- So sánh vùng chú ý giữa BERT, DistilBERT, BiLSTM trên cùng mẫu
- Transformer tập trung vào từ khóa ngữ nghĩa chính xác hơn
- BiLSTM phân tán attention và có confidence thấp hơn

Efficiency & Ensemble

Hiệu quả mô hình (Latency)

Mô hình	Latency/sample
BiGRU	~2.04 ms
BiLSTM	~2.04 ms
DistilBERT	~4.99 ms
BERT-base	~11.57 ms

*Trade-off: RNN nhanh 5x nhưng F1 thấp hơn ~13%.
DistilBERT layerwise LR là điểm cân bằng tốt nhất.*

Ensemble Results

Phương pháp: Average probability ensemble

Accuracy: 0.7718

Macro F1: 0.7760

Cải thiện so với đa số model đơn, nhưng chưa vượt BERT-base (0.7829).

Kết luận

- Transformer (BERT-base) vượt trội với macro F1 = 0.7829, cao hơn RNN ~13 điểm phần trăm.
- DistilBERT + layerwise LR đạt F1 gần BERT-base (0.7716) với thời gian train nhanh hơn — tốt cho triển khai thực tế.
- RNN (BiLSTM/BiGRU) kém calibrated nhất (ECE cao) và dễ bị ảnh hưởng bởi nhiễu ký tự.
- Ensemble cải thiện so với đa số model đơn nhưng chưa vượt model đơn mạnh nhất.
- Error analysis cho thấy các cặp lớp gần nghĩa (Love ↔ Heavy Emotion, Science ↔ Health) là thách thức chung cho mọi mô hình.
- Interpretability: Transformer tập trung attention chính xác hơn vào từ khóa ngữ nghĩa so với RNN.

03

MULTIMODAL CLASSIFICATION

AGENDA

01

DATASET & EDA

02

ZERO-SHOT
CLASSIFICATION

03

FEW-SHOT CLASSIFICATION

04

MỞ RỘNG & KẾT LUẬN

Tổng quan tập dữ liệu

Nguồn: COCO 2017 (images + captions + instance annotations)

Loại dữ liệu: Đa phương thức — mỗi mẫu gồm ảnh + caption mô tả

Nhãn: 8 supercategory (animal, vehicle, food, furniture, person, outdoor, electronic, kitchen)

Kích thước: ~5,400 mẫu (lấy từ train2017 + val2017)

Chia dữ liệu: Stratified split 70/15/15

Train: 3,781 / Val: 810 / Test: 811

Đặc trưng đa phương thức: Cặp ảnh–caption thực sự (cùng mô tả đối tượng/sự kiện), không ghép ngẫu nhiên.

Backbone: CLIP (ViT-B/32) — encode ảnh + text thành vector 512-d cùng không gian.

Phân tích dữ liệu (EDA)

Phân phối lớp

8 supercategory với animal chiếm nhiều nhất. Phân phối không đều nhưng đủ mẫu mỗi lớp (≥ 120).

Độ dài caption

Trung bình ~ 10 từ/caption, biến thiên đều giữa các lớp và split.

CLIP alignment

Image-text cosine similarity trung bình ~ 0.25 . Cho thấy ảnh và caption có mối liên hệ ngữ nghĩa, nhưng không trivial.

PCA Embedding

Fused embedding (image+text) tạo cụm rõ ràng hơn image-only hoặc text-only, đặc biệt với animal, person, vehicle.

ZERO-SHOT CLASSIFICATION

Zero-shot Classification

Phương pháp

Sử dụng CLIP (ViT-B/32) kết hợp multi-prompt templates + Visual-Aligned Prompt Fusion (VAPF).

Multi-prompt: Tạo nhiều prompt ("a photo of {class}", "an image containing {class}", ...) rồi trung bình class prototype.

VAPF: Tìm α tối ưu trên validation để cân bằng image vs text embedding:

$$fused = \alpha \times image_emb + (1-\alpha) \times text_emb$$

Best $\alpha = 0.90$ (ưu tiên image embedding)

Kết quả trên Test set

Accuracy = 0.5721

Macro F1 = 0.4868

Không cần dữ liệu huấn luyện — chỉ dùng class name và CLIP pretrained.

FEW-SHOT CLASSIFICATION

Few-shot Classification

Cấu hình Few-shot: $K = 16$ mẫu/lớp (128 mẫu tổng cho 8 lớp).

CLIP + Logistic Regression (tuned)

Grid search α (0.10–0.90) $\times$ C (0.05–20). Best: $\alpha=0.80$, $C=5.0$.

Test: Acc=0.6621, Macro F1=0.6434 (cao nhất)

CLIP + SVM (Linear)

Test: Acc=0.6239, Macro F1=0.6235

CLIP + MLP (hidden=256)

Test: Acc=0.6264, Macro F1=0.6098

CNN (ResNet18) + LR (image-only)

Test: Acc=0.5351, Macro F1=0.5062

CLIP-head Fine-tune (end-to-end)

Test: Acc=0.4599, Macro F1=0.4394 (overfitting do K nhỏ)


KẾT QUẢ THỰC NGHIỆM

Bảng tổng hợp kết quả

Mô hình	Approach	Accuracy	Macro F1
CLIP Zero-shot (VAPF)	Zero-shot	0.5721	0.4868
CNN ResNet18 + LR	Few-shot	0.5351	0.5062
CLIP + MLP	Few-shot	0.6264	0.6098
CLIP + SVM	Few-shot	0.6239	0.6235
CLIP-head Fine-tune	Few-shot	0.4599	0.4394
Ensemble (ZS+Few, $\alpha=0.7$)	Kết hợp	0.6597	0.6394
CLIP + LR (tuned)	Few-shot	0.6621	0.6434

Few-shot CLIP + LR đạt kết quả tốt nhất. Zero-shot cho baseline hợp lý mà không cần dữ liệu train.

So sánh Macro F1



So sánh Zero-shot vs Few-shot

Zero-shot (Multi-prompt + VAPF)

Ưu điểm:

- Không cần dữ liệu train
- Triển khai nhanh, không fine-tune

Hạn chế:

- Accuracy thấp hơn (~57%)
- ECE cao (0.442) — kém calibrated
- Phụ thuộc prompt template

Few-shot (K=16, CLIP + LR tuned)

Ưu điểm:

- Accuracy cao nhất (~66%)
- ECE tốt hơn (0.224)
- Robust hơn trước nhiễu

Hạn chế:

- Cần ít nhất K mẫu/lớp
- Cần grid search α , C

Few-shot với chỉ 128 mẫu (16/lớp) đã cải thiện Macro F1 từ 0.49 lên 0.64 (+32%).

MỞ RỘNG

Calibration & Robustness

Calibration (ECE)

Mô hình	ECE ↓
CNN ResNet18+LR	0.176
Few-shot CLIP+LR	0.224
Zero-shot CLIP	0.442

Zero-shot kém calibrated nhất ($ECE=0.442$). CNN image-only có ECE tốt nhất.

Robustness (Text dropout + Blur)

	Clean F1	Robust F1	Δ
Zero-shot	0.487	0.452	-0.035
Few-shot LR	0.643	0.629	-0.014

Few-shot bền hơn trước nhiễu (giảm chỉ 0.014 F1).
Zero-shot nhạy cảm hơn.

K Ablation, Ensemble & Interpretability

K Ablation (Few-shot LR)

- K=8: Macro F1 = 0.614
- K=16: Macro F1 = 0.643
- K=32: Macro F1 = 0.669

Tăng K mang lại lợi ích rõ ràng.

Ensemble (ZS + Few-shot)

- $\alpha=0.7$ (70% few-shot + 30% zero-shot)
- Acc=0.6597, Macro F1=0.6394

Gần bằng few-shot đơn, không vượt qua.

Interpretability

Token Importance:

Bỏ từng token khỏi caption, đo confidence drop. Từ khóa ngữ nghĩa ("dog", "food") gây drop lớn nhất.

Image Occlusion:

Che vùng ảnh 7×7 grid, đo confidence drop. Vùng chứa đối tượng chính gây drop lớn nhất.

Kết luận: CLIP tập trung đúng vào đối tượng chính trong cả ảnh lẫn caption khi phân loại.

Kết luận

- Few-shot CLIP + LR đạt kết quả tốt nhất (Macro F1 = 0.6434) chỉ với 16 mẫu/lớp, vượt trội so với zero-shot (+32%).
- Zero-shot CLIP (Multi-prompt + VAPF) cho baseline hợp lý (Acc=57%) mà không cần dữ liệu train — phù hợp khi chưa có labeled data.
- CLIP-head fine-tune với K nhỏ dễ overfit — linear probe (LR/SVM) hiệu quả hơn trong low-resource regime.
- Multimodal fusion (image + text) luôn tốt hơn image-only (CNN ResNet18 chỉ đạt F1=0.50).
- Few-shot bền hơn trước nhiễu (F1 giảm chỉ 0.014 vs 0.035 của zero-shot) và calibrated tốt hơn (ECE 0.224 vs 0.442).
- Tăng K (8→16→32) cải thiện đều đặn, cho thấy lợi ích rõ ràng của việc thêm labeled data.

**MANY THANKS
FOR YOUR LISTENING!**