



Vietnam National University
Ho Chi Minh City University of Technology

Assignment 3

Phân đoạn ảnh với các mô hình học sâu cơ bản

Group 9


Course: **Học sâu và ứng dụng trong thị giác máy tính**

Lecturer: TS Lê Thành Sách

Members

Huỳnh Văn Tâm Thiện - 2470094

Trần Lê Phú - 2470307



Source Code

<https://colab.research.google.com/drive/1VWi8xVAyESxcBUT05oVugBwzv0MQ3B8S?usp=sharing>

Repository

https://github.com/tranlephu1207/79747_CO5085_001995_SDH_assignments/tree/master/assignment3_segmentation

Contents


- 01** Tập dữ liệu & EDA
- 02** Xây dựng các mô hình phân loại
- 03** Huấn luyện, đánh giá & so sánh
- 04** Tự hiện thực TransformerEncoder & ViT
- 05** Các kiến trúc kết hợp & cách embed ảnh khác nhau
- 06** Mô hình phân loại dựa trên LSTM/GRU
- 07** Tổng hợp kết quả

01

Tập dữ liệu & EDA


Tổng quan tập dữ liệu

- **Nguồn:** ADE20K
- **Tổng số mẫu:** Training set: 20,210 ảnh + mask, tập Validation: 2,000 ảnh + mask
- **Loại bài toán:** Phân đoạn ảnh.
- **Chia tập dữ liệu:**
 - Tập train: 20,210 ảnh + mask từ tập train gốc.
 - Tập validation: 1.000 ảnh + mask từ tập validation gốc.
 - Tập test: 1.000 ảnh + mask từ tập validation gốc.



Phân tích dữ liệu (EDA)

- Dữ liệu gồm 150 lớp
- Dữ liệu có sự mất cân bằng lớp rõ rệt, lớp "wall" (tường) chiếm tỷ lệ pixel cao nhất (15.7%), tiếp sau là "building" và "sky"
- width min/max: 175 1516
- height min/max: 125 1516



Kỹ thuật augmentation:

- **Random Scale:** Thay đổi kích thước ngẫu nhiên từ 0.75x đến 1.5x.
- **Horizontal Flip:** Lật ảnh ngang với xác suất 50%.
- **Color Jitter:** Thay đổi độ sáng, tương phản, độ bão hòa



Original (Image)



Original (Mask)



Scale (1.5x) (Image)



Scale (1.5x) (Mask)



H-Flip (Image)



H-Flip (Mask)



Color jitter (Image)



Color jitter (Mask)

02

Xây dựng và huấn luyện các mô hình phân loại

Cấu hình huấn luyện

Image Size: 384*384.

Batch Size: 24.

Learning Rate: 3e-4.

Epochs: 10.


Optimizer: AdamW (Weight decay 1e-4).

Kỹ thuật hỗ trợ: Sử dụng Mixed Precision (AMP) để tăng tốc và tiết kiệm VRAM

Custom U-Net (UNetSmall)


Kiến trúc này tuân theo cấu trúc hình chữ 'U':

- Bộ mã hóa (Encoder): Gồm các khối DoubleConv (Conv -> BatchNorm -> ReLU) và MaxPool2d để trích xuất đặc trưng và giảm độ phân giải (tương tự mạng phân loại).
- Bộ giải mã (Decoder): Sử dụng ConvTranspose2d để khôi phục kích thước hình ảnh.
- Skip Connections: kết hợp đặc trưng chi tiết từ Encoder trực tiếp sang Decoder, giúp mô hình giữ được thông tin vị trí chính xác của vật thể.
- Phiên bản 'Small' vì sử dụng số lượng kênh cơ bản (base_ch=32) thấp hơn bản gốc để tiết kiệm bộ nhớ.




DeepLabV3-ResNet50

- **ASPP (Atrous Spatial Pyramid Pooling):** Đây là 'trái tim' của mô hình, giúp lấy mẫu đặc trưng ở nhiều tỉ lệ khác nhau (dilated rates khác nhau) cùng lúc, cho phép mô hình hiểu được cả vật thể rất lớn và rất nhỏ trong ảnh.
- **Image Pooling:** Global Average Pooling để lấy thông tin toàn cảnh (global context) của bức ảnh.
- **Backbone:** Sử dụng ResNet50 đã được huấn luyện sẵn trên ImageNet, giúp mô hình có khả năng trích xuất đặc trưng tốt.




FCN-ResNet50 (Fully Convolutional Network)

- Fully Convolutional: Thay thế hoàn toàn các lớp Fully Connected (FC) ở cuối mạng ResNet bằng các lớp Convolution. Điều này cho phép mạng nhận đầu vào với kích thước bất kỳ và tạo ra bản đồ xác suất (probability map).
- Cơ chế hoạt động: Nó thực hiện phân loại ở cấp độ pixel. Tuy nhiên, vì FCN thường làm giảm độ phân giải, nên nó sử dụng phép nội suy (interpolation) hoặc 'deconvolution' đơn giản ở cuối để đưa ảnh về kích thước gốc.



Huấn luyện mô hình

- DeepLabV3 đạt mIoU cao nhất (vượt mốc 0.35), chứng minh ưu thế của khối ASPP trong việc xử lý các vật thể trên tập ADE20K.
- Hội tụ nhanh và ổn định: 3 mô hình đều giảm Loss mạnh và ổn định sau 8 epoch, trong đó DeepLabV3 đạt mức sai số (Validation Loss) thấp nhất và Val mIoU cao nhất.
- FCN có mức Val Loss cao nhất cho thấy kiến trúc đơn giản chưa tối ưu cho tập dữ liệu phức tạp như ADE20K



03

Đánh giá và so sánh

So sánh tổng thể trên tập Val và Test

Nhận xét:

- DeepLabV3 đạt kết quả tốt nhất trên mọi metric nhờ ASPP + pretrained backbone
- Val $\approx$ Test metrics $\rightarrow$ chiến lược chia val/test đảm bảo đánh giá công bằng, không data leakage
- UNet Small thua rất xa do train from scratch, không pretrained

	experiment	best_epoch	best_val_mIoU	best_val_mDice	best_val_pixel_acc	val_loss_at_best
0	deeplabv3_resnet50	10	0.390049	0.521260	0.792676	0.709102
1	fcn_resnet50	10	0.376869	0.510877	0.777716	0.779795
2	unet_small	10	0.055268	0.077204	0.590510	1.696974

Phân tích Top-5 / Bottom-5 classes (UNet Small)

Test mIoU: 0.0556 | Test mDice: 0.0782

Top-5 classes:

Class	Test IoU	Nhận xét
sky	0.8723	Vùng lớn, màu đồng nhất — dễ nhất kể cả model yếu
ceiling	0.6023	Vùng lớn, thường đồng màu
building, edifice	0.5536	Vùng lớn outdoor
tree	0.5184	Texture lá cây đặc trưng
road, route	0.5055	Vùng lớn, vị trí cố định (dưới ảnh)

Bottom-5 classes:

Class	Test IoU	Nhận xét
shower	0.0000	Nhỏ, hiếm
radiator	0.0000	Nhỏ, ít mẫu
glass, drinking glass	0.0000	Rất nhỏ, trong suốt
clock	0.0000	Rất nhỏ
flag	0.0000	Hiếm, nhỏ

Nhận xét: UNet chỉ nhận diện được 5–6 classes vùng lớn, còn lại gần như IoU = 0. Thiếu pretrained features khiến model không đủ khả năng phân biệt 150 classes.

Phân tích Top-5 / Bottom-5 classes (DeepLabV3)

Nhận xét: ASPP + pretrained giúp nhận diện tốt cả classes có texture đặc trưng (tent, pool table) chứ không chỉ vùng lớn đơn giản như UNet.

Test mIoU: 0.3932 | Test mDice: 0.5231

Top-5 classes:

Class	Test IoU	Nhận xét
sky	0.9361	Cao nhất, vùng lớn + màu đặc trưng
tent	0.9039	Hình dạng + texture riêng biệt
pool table	0.8995	Màu xanh đặc trưng, hình chữ nhật
swimming pool	0.8616	Vùng lớn, màu nước đặc trưng
bed	0.8427	Chiếm phần lớn indoor scene

Bottom-5 classes:

Class	Test IoU	Nhận xét
ship	0.0000	Rất hiếm trong dataset
conveyor belt	0.0000	Hiếm, dễ nhầm với sàn/máy
lake	0.0000	Nhầm với swimming pool/river
CRT screen	0.0000	Nhỏ, giống TV/monitor
shower	0.0000	Nhỏ, hiếm

Phân tích Top-5 / Bottom-5 classes (FCN)

Test mIoU: 0.3688 | Test mDice: 0.5038

Top-5 classes:

Class	Test IoU	Nhận xét
sky	0.9345	Gần bằng DeepLabV3
pool table	0.8674	Thấp hơn DeepLabV3 3.2%
bed	0.7856	Thấp hơn DeepLabV3 5.7%
toilet	0.7729	Hình dạng đặc trưng, vùng trung bình
car	0.7640	Hình dạng rõ, outdoor scene

Bottom-5 classes:

Class	Test IoU	Nhận xét
bannister	0.0068	Gần 0 nhưng không hoàn toàn 0
CRT screen	0.0009	Gần như miss hoàn toàn
ship	0.0000	Hiếm
conveyor belt	0.0000	Hiếm
shower	0.0000	Hiếm, nhỏ

Nhận xét: FCN có cùng backbone pretrained nên Top classes tương tự DeepLabV3, nhưng IoU thấp hơn 3–6% ở mỗi class → thiếu ASPP khiến khả năng phân biệt chi tiết kém hơn.

So sánh Top-5 classes chung giữa 3 models

Class	UNet	FCN	DeepLabV3	Nhận xét
sky	0.8723	0.9345	0.9361	Cả 3 đều tốt — class dễ nhất
bed	—	0.7856	0.8427	DeepLabV3 hơn 5.7% nhờ ASPP
pool table	—	0.8674	0.8995	DeepLabV3 hơn 3.2%
building	0.5536	—	—	UNet chỉ nhận vùng cực lớn
car	—	0.7640	—	FCN tốt với objects có hình dạng rõ

Nhận xét:

- sky là class duy nhất cả 3 models đều làm tốt (>0.87)
- UNet Top-5 chỉ gồm classes vùng cực lớn (sky, ceiling, building, tree, road)
- DeepLabV3 và FCN mở rộng được sang classes texture đặc trưng (tent, pool table, toilet)
- DeepLabV3 consistently hơn FCN 3–6% IoU ở cùng class nhờ multi-scale reasoning của ASPP

Test-Time Augmentation (TTA)

Mô hình	Test mIoU (no TTA)	Test mIoU (TTA)	Delta
DeepLabV3	0.3932	0.3979	+0.0048
FCN-ResNet50	0.3688	0.3752	+0.0065
UNet Small	0.0556	0.0561	+0.0005


Phương pháp: Inference 2 lần (ảnh gốc + horizontal flip) → trung bình logits

Nhận xét:

- TTA cải thiện nhất quán cho cả 3 mô hình.
- FCN hưởng lợi nhiều nhất (+0.65%), mô hình hưởng lợi nhiều hơn từ ensemble.
- UNet gần như không thay đổi do mô hình quá yếu, TTA không giúp được.
- Đánh đổi: 2× thời gian inference cho ~0.5% cải thiện.

Kết quả trực quan


- **Vùng lớn, đồng nhất (sky, wall, person, bed):** prediction khá chính xác.
- **Boundary giữa objects:** bị mờ (blur) do upsample từ feature map có độ phân giải thấp.
- **Các Objects nhỏ (đèn, đồ vật, khung ảnh):** thường bị bỏ qua hoặc nhầm class.
- **Các cảnh trong nhà phức tạp (bếp, phòng ngủ):** nhiều noise hơn cảnh bên ngoài vì mật độ các objects cao.



Grad-CAM Visualization

Nhận xét chung:


- **UNet:** Heatmaps giống nhau giữa các mẫu → model không đủ capacity để spatial discrimination. **Giải thích mIoU chỉ 5.6%**
- **DeepLabV3:** Heatmap tập trung, boundary rõ → ASPP + pretrained backbone giúp focus chính xác. Tương ứng mIoU 39.3%
- **FCN:** Trung gian — có focus nhưng kém sharp, activation hay tràn sang class lân cận → thiếu ASPP. Tương ứng mIoU 36.9%
- **Kết luận:** Chất lượng Grad-CAM tương quan trực tiếp với test mIoU — model càng mạnh, attention càng chính xác



Grad-CAM Multi-class: So sánh 3 mô hình

Nhận xét chung:

- **UNet:** Heatmaps gần như giống nhau giữa 5 classes → model không học được cách phân biệt vùng spatial cho từng class. Đây là nguyên nhân chính mIoU chỉ 5.6%
- **DeepLabV3:** Mỗi class activate vùng riêng biệt rõ ràng — rock ≠ ground ≠ tree dù ở gần nhau → ASPP module giúp multi-scale reasoning hiệu quả
- **FCN:** Có phân biệt được nhưng boundary hay bị tràn sang class lân cận → cùng pretrained backbone nhưng thiếu ASPP khiến localization kém hơn 2.4% mIoU
- **Kết luận:** Grad-CAM multi-class xác nhận DeepLabV3 có spatial discrimination tốt nhất, nhất quán với ranking test mIoU



Demo bằng DeepLabV3



- Model segment được vùng chính tốt: mèo, sàn, tường, lò sưởi
- Boundary mèo khá chính xác, đặc biệt tai và đầu
- Background phức tạp (lò sưởi, kệ sách) gây nhiều noise ở vùng nhỏ
- Grad-CAM xác nhận model focus đúng vùng spatial của target class
- Ảnh mèo không thuộc ADE20K training data (không có class "cat" riêng) → model vẫn segment được nhờ generalize từ các class tương tự, cho thấy khả năng generalization tốt của DeepLabV3

Tổng kết

1. **DeepLabV3 > FCN > UNet** trên mọi metric — ASPP + pretrained backbone là chìa khóa
2. **Pretrained backbone quyết định** — gap 33.7% mIoU giữa có và không pretrained
3. **TTA cải thiện +0.5–0.6%** mIoU với chi phí 2× inference time
4. **Class imbalance** là thách thức lớn nhất — rare/small classes đạt IoU ≈ 0
5. **Grad-CAM xác nhận** model học spatial features có ý nghĩa

The slide features a white background with two solid blue squares: one in the top-left corner and one in the bottom-right corner. Centered on the slide is the text "Thank you!" in a large, bold, blue sans-serif font.

Thank you!